

Entrega 2 — Selección de idea de proyecto y análisis de datos necesarios

1. Idea seleccionada

Stocker: sistema de histórico y predicción diaria del precio de una acción

Problema que resuelve. Un inversor particular o trader retail que sigue una acción concreta (por ejemplo, AAPL) no suele disponer de herramientas propias que centralicen el histórico de precios y le den una referencia cuantitativa sobre hacia dónde puede moverse el precio al día siguiente. La mayoría de plataformas gratuitas ofrecen gráficos y datos crudos, pero no una estimación propia, personalizable y explicable del movimiento a corto plazo. Este proyecto resuelve esa carencia para un usuario individual que quiere tener su propia base de datos histórica de una acción y un indicador orientativo diario, sin depender de terceros ni de suscripciones de pago.

Solución planteada. El enfoque combina dos piezas de Data Science: primero, una base de datos histórica de precios (Open, High, Low, Close, Volumen) de una acción concreta, alimentada mediante la API de Yahoo Finance y actualizada de forma periódica; segundo, un modelo predictivo supervisado que, a partir de los datos de Open y Close (y variables derivadas como medias móviles o retornos diarios), estime el precio de cierre del día siguiente. El modelo se entrenará y validará sobre el histórico, comparando el error de predicción frente a enfoques ingenuos (como usar el cierre de hoy como predicción de mañana), lo que permitirá cuantificar honestamente el valor real que aporta el modelo frente al ruido inherente al mercado.

MVP del proyecto final. El producto mínimo viable constará de: (1) un pipeline de recogida y actualización de datos que descargue el histórico de la acción elegida y lo mantenga al día; (2) un modelo entrenado (por ejemplo, regresión o un modelo de series temporales) que prediga el precio de cierre del día siguiente; y (3) una visualización (dashboard o notebook con gráficos) que muestre el histórico real junto con la predicción del modelo y sus métricas de error (MAE, RMSE, comparación con el baseline). Quedará fuera del MVP la cobertura de múltiples acciones simultáneas y la incorporación de fuentes alternativas (noticias, sentimiento, datos macro), que se plantean como posibles ampliaciones si el tiempo del curso lo permite.

2. Datos necesarios

- **Variables/campos:** fecha (Date), precio de apertura (Open), máximo (High), mínimo (Low), cierre (Close), cierre ajustado (Adj Close) y volumen (Volume). A partir de estas se derivarán variables de apoyo: retorno diario, medias móviles (5, 10, 20 días), volatilidad reciente y el propio precio de cierre desplazado (target del día siguiente).
- **Granularidad:** diaria, por acción (una única acción concreta para el MVP, ej. AAPL). No se contempla granularidad intradía en esta fase.

- **Profundidad histórica:** se considera necesario un mínimo de 3-5 años de histórico diario para que el modelo tenga suficientes ejemplos y cubra distintos regímenes de mercado (subidas, caídas, alta y baja volatilidad). Idealmente 8-10 años si el volumen de filas resultante sigue siendo manejable.
- **Volumen aproximado:** con datos diarios, cada año aporta ~250 sesiones de mercado, por lo que 5 años suponen ~1.250 filas y 10 años ~2.500 filas para una sola acción. Es un volumen modesto pero razonable para un modelo de regresión/series temporales con feature engineering, no para modelos de deep learning que requieran mucho más dato.
- **Imprescindibles:** Date, Open, Close (mencionados explícitamente en el enunciado del proyecto), y Volume (habitual y sin coste adicional obtenerlo).
- **Deseables, no obligatorios:** High/Low (para features de rango diario), datos de dividendos y splits (para interpretar correctamente el Adj Close), y en una fase posterior, variables externas como índices de referencia (S&P 500), tipos de interés o sentimiento de noticias, que enriquecerían el modelo pero no son necesarias para el MVP.

3. Fuentes de datos previstas

- **Fuente concreta:** API de Yahoo Finance, accedida mediante la librería `yfinance` de Python, que descarga los datos y los persiste en ficheros CSV.
- **Accesibilidad:** es una fuente abierta y gratuita, sin necesidad de registro ni de API key, con un límite de uso razonable para un proyecto académico de esta escala.
- **Enlaces:** finance.yahoo.com y pypi.org/project/yfinance.
- **Formato esperado:** CSV, generado a partir de un DataFrame de pandas obtenido con `yfinance`.
- **Histórico disponible:** sí; para una acción como AAPL, Yahoo Finance ofrece histórico diario de varias décadas.
- **Estabilidad de la fuente:** `yfinance` es una librería ampliamente usada y mantenida activamente por la comunidad, pero no es una API oficial de Yahoo, sino un cliente que interactúa con endpoints internos de su web. Esto la hace muy práctica pero no garantizada a largo plazo.
- **Riesgos detectados:**
 - Al no ser una API oficial, cambios internos en la web de Yahoo Finance pueden romper temporalmente `yfinance` hasta que la comunidad publique una actualización.
 - Posibles límites de peticiones si se automatiza una descarga diaria sin control de frecuencia.
 - Necesidad de manejar correctamente los días sin cotización (fines de semana, festivos de mercado) para no introducir huecos mal interpretados como datos faltantes.
 - La actualización diaria automática es técnicamente viable (Yahoo publica el cierre poco después del cierre de mercado), pero requiere programar la tarea

respetando la zona horaria del mercado (ET, NYSE/NASDAQ) y prever qué hacer si algún día la descarga falla.

4. Consideraciones de privacidad y protección de datos

- Los datos son de mercado público (precios históricos de una acción cotizada) y en ningún caso incluyen información personal identificable de individuos.
- No es necesario anonimizar, agregar ni filtrar ninguna información, dado que no hay datos de usuarios ni de terceros implicados.
- Los datos pueden usarse de forma segura para un proyecto académico sin ninguna restricción relevante de privacidad.
- El único riesgo a tener en cuenta no es de privacidad sino de uso responsable: el proyecto debe dejar claro (mediante un disclaimer) que no constituye asesoramiento financiero real, dado que un modelo predictivo sobre precios de acciones puede malinterpretarse como una recomendación de inversión si no se contextualiza adecuadamente.
- No se ha descartado ningún dato por motivos de privacidad, ya que toda la información de partida es pública y no personal.

5. Viabilidad inicial del proyecto

- **¿Es viable obtener los datos?** Sí. Yahoo Finance a través de `yfinance` es una de las fuentes más accesibles y utilizadas para este tipo de proyectos, y ya se ha probado su funcionamiento en una primera prueba.
- **¿Calidad, granularidad e histórico suficientes?** Sí para un MVP centrado en una acción: la granularidad diaria y varios años de histórico permiten entrenar y validar un modelo de forma razonable, aunque el volumen de filas (unos pocos miles) limita el uso de modelos muy complejos.
- **¿Es realista desarrollarlo durante el curso?** Sí, el alcance (una acción, datos OHLCV, un modelo de regresión/series temporales, una visualización comparativa) es acotado y factible en el tiempo disponible.
- **Parte más arriesgada.** La capacidad predictiva real del modelo: los precios de cierre a corto plazo se comportan de forma cercana a un paseo aleatorio, por lo que existe un riesgo real de que el modelo no supere de forma significativa a un baseline ingenuo (usar el cierre de hoy como predicción de mañana). Gestionar esta expectativa con honestidad analítica —mostrando la comparación frente al baseline— será clave. El segundo riesgo es la dependencia de una librería no oficial (`yfinance`) para la actualización diaria automatizada.
- **Alternativa si la fuente principal falla.** Como alternativas se contemplan Alpha Vantage (API oficial con clave gratuita, aunque con límites de peticiones más estrictos), Stooq (descargas CSV directas) o datasets históricos ya recopilados en Kaggle, que permitirían mantener el proyecto en marcha si `yfinance` dejara de funcionar de forma fiable.

